Numero di crimini orari ad Atlanta: confronto tra modelli per dati di conteggio

Simone Squizzato - n. mat. 0222401031

A.A. 2025/2026

Abstract

Il seguente studio ha come obiettivo l'analisi e la previsione del numero di crimini commessi in una determinata fascia oraria nella città di Atlanta (Georgia, USA). Tali previsioni sono ottenute mediante l'utilizzo di diversi modelli per dati di conteggio, tra cui modelli di Poisson, Zero-Inflated Poisson e Hurdle. Data la natura dei dati analizzati, la scelta che risulterà ottimale, in termini di RMSE, sarà il modello Zero-Inflated Poisson; in termini di MAE, sarà il modello Hurdle Poisson. Analizzate ulteriormente le proprietà dei residui dei modelli e delle previsioni ottenute, tra i due risulterà preferibile il modello Hurdle.

1 Obiettivo di studio e introduzione al dataset

L'obiettivo dell'analisi è la previsione del numero di crimini commessi in una determinata fascia oraria nella città di Atlanta (Georgia, USA), il dataset in questione deriva da un dataset aggregato del FBI per lo stato della Georgia, reperibile su kaggle.com al seguente link:

`https://www.kaggle.com/datasets/joshuapina/core-atlanta-burglary-related-crimes-2021-2025`

I dati contengono un osservazione per ogni ora del giorno a partire dal primo gennaio 2021 al 27 novembre 2025, la variabile di interesse è relativa al numero di crimini commessi all'interno di una singola ora nell'intera città di Atlanta. Oltre a tale informazione è nota la zona della città, abbreviata come npu, la media di crimini registrati in quella zona negli ultimi 30 giorni, oltre alla vicinanza a punti di interesse della città e alle condizioni atmosferiche al momento della registrazione del crimine.

In particolare, il dataset contiene 1'074'500 osservazioni; essendo strutturato come una serie temporale la suddivisione del dataset in training e test set è stata effettuata in maniera sequenziale e non casuale, in proporzione 80% per il training set e il restante 20% per il test set. Il dataset è composto dalle seguenti variabili:

- Crime_Count: numero di crimini commessi in un'ora;
- Npu: acronimo per Neighborhood Planning Unit, che è un consiglio formato da cittadini specifico e caratteristico del sistema di governance della città di Atlanta, la quale è divisa geograficamente in 25 unità (contrassegnate dalle lettere dalla A alla Z);
- Npu_Crime_Avg_30d: numero di crimini nella npu negli ultimi 30 giorni;
- Near_: serie di variabili binarie che identificano la vicinanza a punti di interesse della città;

- Is_: serie di variabili binarie che identificano caratteristiche metereologiche e temporali;
- Temp_f: temperatura registrata in °F.

1.1 EDA

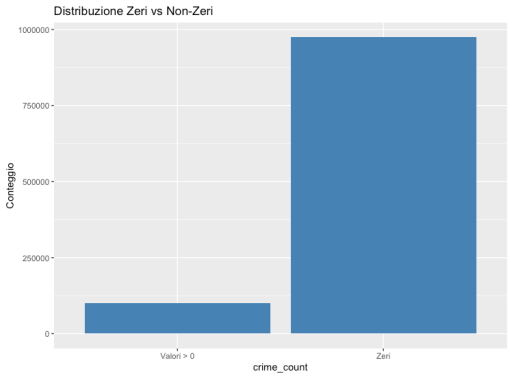
L'analisi preliminare del dataset parte dall'analisi e dalla visualizzazione delle variabili contenute nello stesso attraverso un summary dei dati.

```
 crime_count          npu         npu_crime_avg_30d     temp_f       near_gsu
Min.   : 0.0000   A      : 42980   Min.   : 0.0000   Min.   : 0.000   0:1065729
1st Qu.: 0.0000   B      : 42980   1st Qu.: 0.0000   1st Qu.: 0.000   1:   8771
Median : 0.0000   C      : 42980   Median : 0.0000   Median : 0.000
Mean   : 0.1056   D      : 42980   Mean   : 0.9266   Mean   : 5.965
3rd Qu.: 0.0000   E      : 42980   3rd Qu.: 0.0000   3rd Qu.: 0.000
Max.   :16.0000   F      : 42980   Max.   :34.6667   Max.   :99.944
                  (Other):816620
near_ga_tech near_emory  near_clark  near_spelman near_morehouse near_morehouse_med
0:1064056    0:1074297   0:1071113   0:1069316    0:1073660      0:1073863
1:  10444    1:    203   1:   3387   1:   5184    1:    840      1:    637

near_atlanta_metro near_atlanta_tech near_scad   near_john_marshall
0:1071125          0:1072464         0:1067097   0:1066095
1:   3375          1:   2036         1:   7403   1:   8405
```

Figura 1: Summary dei dati

Dal summary dei dati è possibile notare come le occorrenze delle singole npu siano equiparate per tutti i livelli, e come la maggior parte dei dati sia contrassegnata da zeri. Tale constatazione deriva dalla natura del dataset che registra unità statistiche tutte pari a zero in assenza del fenomeno criminoso; ciò comporta che la descrizione delle variabili risulti complessivamente fuorviante e di difficile interpretazione. Analizziamo quante volte effettivamente il numero di crimini registrato sia diverso da zero, e la sua distribuzione.



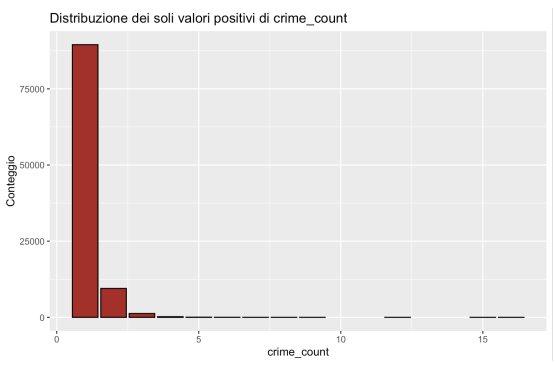
Il totale di osservazioni in cui il numero di crimini è pari a zero è 974003 che rappresentano il 90.65% dei dati, i restanti 100497 o 9.35% sono valori positivi. Vediamo ora come cambia la conformazione del dataset prendendo in esame solo la parte positiva dei dati.

```
 crime_count          npu         npu_crime_avg_30d     temp_f       near_gsu  near_ga_tech
Min.   : 1.000   M      :13398   Min.   : 0.000    Min.   : 0.00   0:91726   0:90053
1st Qu.: 1.000   E      :12997   1st Qu.: 4.333    1st Qu.:52.60   1: 8771   1:10444
Median : 1.000   B      :10722   Median : 5.967    Median :66.01
Mean   : 1.129   F      : 4761   Mean   : 9.907    Mean   :63.78
3rd Qu.: 1.000   N      : 4717   3rd Qu.:16.133    3rd Qu.:75.28
Max.   :16.000   V      : 4601   Max.   :34.667    Max.   :99.94
                 (Other):49301
near_emory near_clark near_spelman near_morehouse near_morehouse_med near_atlanta_metro
0:100294   0:97110    0:95313      0:99657        0:99860             0:97122
1:   203   1: 3387    1: 5184      1:  840        1:  637             1: 3375

near_atlanta_tech near_scad near_john_marshall
0:98461           0:93094   0:92092
1: 2036           1: 7403   1: 8405
```

Figura 2: Summary dei dati diversi da zero

L'analisi di questi valori risulta essere ora maggiormente significativa a scopo interpretativo, si nota come il numero di crimini commessi in un'ora sia generalmente pari a uno ma arrivi fino a un massimo di sedici; che i neighbourhood in cui si presentano più crimini sono M, E e B. Inoltre, circa il 10% dei crimini avviene nella zona del Georgia Institute of Technology (near_ga_tech) nella zona Midtown di Atlanta, mentre nella zona Downtown si trovano la Georgia State University (near_gsu) e la John Marshall University (near_john_marshall) che insieme combinano un ulteriore 17% dei crimini registrati.



2 Metodologia

Analizziamo di seguito quali modelli sono stati stimati per la corretta previsione del numero futuro di crimini commessi per ogni ora.

2.1 Stima del modello di Poisson

Se si ipotizza la costruzione di un modello di regressione di Poisson stiamo formalmente ipotizzando che $Y|\mathbf{x} \sim Pois(\lambda)$, dove la distribuzione di probabilità di Poisson per una variabile Y è data da:

$$Pr(Y = y) = \exp(-\lambda)\frac{\lambda^y}{y!}, \quad y = 0, 1, \dots \tag{1}$$

nel caso della regressione di Poisson definiamo $g(\lambda) = \mathbf{x}'\beta$ e la link function logaritmica tale che $\log(\lambda) = \mathbf{x}'\beta$ e di conseguenza $\lambda = \exp(\mathbf{x}'\beta)$. Tale impostazione del problema di regressione ci permette di descrivere l'impatto moltiplicativo delle variabili esplicative sulla media.

2.2 Stima del modello Zero-Inflated Poisson (ZIP)

Il modello Zero-Inflated Poisson (ZIP) è utile nel caso in cui alcuni zeri osservabili all'interno del set di dati siano dovuti all'assenza di una caratteristica e non dallo stretto conteggio della stessa; in questo caso si divideranno gli zeri osservati in zeri strutturali e chance zero (zeri casuali). La presenza di zeri strutturali influisce nel numero complessivo di zero, gonfiandolo (inflation), per questo motivo è necessario utilizzare un modello apposito che tenga conto di questa possibilità.

La distribuzione di probabilità di un modello zero-inflated Poisson è:

$$Pr(Y = y|\mathbf{x}) = \begin{cases} \pi + (1-\pi)\exp(-\lambda), & \text{se } y = 0 \\ (1-\pi)\frac{\lambda^y \exp(-\lambda)}{y!}, & \text{se } y = 1, 2, \dots \end{cases} \tag{2}$$

dove:

$$\pi = \frac{\exp(\beta_0 + \beta_1 X_1 + \cdots + \beta_m X_m)}{1 + \exp(\beta_0 + \beta_1 X_1 + \cdots + \beta_m X_m)} \tag{3}$$

e:

$$\lambda = \exp(\gamma_0 + \gamma_1 X_{m+1} + \cdots + \gamma_{p-m} X_p) \tag{4}$$

I primi m predittori sono usati per modellare la probabilità di zero strutturali π, mentre le restanti variabili X sono utilizzate come predittori per la media della Poisson.

Il modello ZIP non fa parte della famiglia delle ED e quindi non appartiene alla classe dei GLM.

2.3 Stima del modello Hurdle

Il modello di regressione Hurdle Poisson è utilizzato quando la variabile di risposta Y ha una distribuzione di Poisson con un numero "gonfiato" di zero e dove gli zeri sono modellati separatamente rispetto a quanto accade nella parte di osservazioni che seguono una Poisson zero-truncated. In particolare, si assume che la variabile Y assuma una probability mass function pari a:

$$Pr(Y = y|\mathbf{x}) = \begin{cases} \pi, & \text{se } y = 0 \\ (1-\pi)\frac{\lambda^y \exp(-\lambda)}{y!(1-\exp(-\lambda))} & \text{altrimenti} \end{cases} \tag{5}$$

dove:

$$\pi = \frac{\exp(\beta_0 + \beta_1 X_1 + \cdots + \beta_m X_m)}{1 + \exp(\beta_0 + \beta_1 X_1 + \cdots + \beta_m X_m)} \tag{6}$$

e:

$$\lambda = \exp(\gamma_0 + \gamma_1 X_{m+1} + \cdots + \gamma_{p-m} X_p) \tag{7}$$

3 Risultati

Di seguito, verifichiamo i risultati ottenuti in termini di interpretabilità del modello e adattabilità ai dati di allenamento, stimati come descritto in precedenza. Solo successivamente verifichiamo le performance previsive degli stessi sul test set.

Il primo modello da discutere è il modello di Poisson con link function logaritmica, di seguito riportiamo la stima dei coefficienti effettuata sul training set:

```
Coefficients:
                       Estimate Std. Error  z value Pr(>|z|)
(Intercept)          -5.298e+00  3.613e-02 -146.615  < 2e-16 ***
npuB                 -9.133e-01  4.281e-02  -21.333  < 2e-16 ***
npuC                  9.169e-01  4.082e-02   22.460  < 2e-16 ***
npuD                  7.760e-01  3.777e-02   20.547  < 2e-16 ***
npuE                 -7.481e-01  4.925e-02  -15.190  < 2e-16 ***
npuF                  1.041e+00  3.852e-02   27.022  < 2e-16 ***
npuG                  8.697e-02  4.065e-02    2.139  0.03240 *
npuH                 -7.155e-01  3.987e-02  -17.948  < 2e-16 ***
npuI                 -1.039e-01  3.809e-02   -2.728  0.00638 **
npuJ                  8.259e-01  4.013e-02   20.579  < 2e-16 ***
npuK                  8.013e-01  4.473e-02   17.915  < 2e-16 ***
npuL                  8.796e-01  4.275e-02   20.574  < 2e-16 ***
npuM                 -1.436e+00  5.647e-02  -25.432  < 2e-16 ***
npuN                  1.161e+00  3.826e-02   30.361  < 2e-16 ***
npuO                  8.997e-01  3.863e-02   23.291  < 2e-16 ***
npuP                 -1.587e+00  4.025e-02  -39.436  < 2e-16 ***
npuQ                 -1.683e+00  9.683e-02  -17.380  < 2e-16 ***
npuR                 -3.514e-01  3.810e-02   -9.222  < 2e-16 ***
npuS                  9.573e-01  4.088e-02   23.415  < 2e-16 ***
npuT                  8.268e-01  4.228e-02   19.555  < 2e-16 ***
npuV                  3.887e-01  4.225e-02    9.199  < 2e-16 ***
npuW                  8.541e-01  3.814e-02   22.390  < 2e-16 ***
npuX                  8.254e-01  4.192e-02   19.691  < 2e-16 ***
npuY                  8.347e-01  4.371e-02   19.096  < 2e-16 ***
npuZ                  3.247e-01  3.903e-02    8.319  < 2e-16 ***
npu_crime_avg_30d     1.572e-01  1.835e-03   85.670  < 2e-16 ***
temp_f                2.493e-02  1.979e-04  125.953  < 2e-16 ***
is_weekend1           8.164e-02  6.942e-03   11.760  < 2e-16 ***
day_number            7.706e-02  1.537e-03   50.143  < 2e-16 ***
hour_sin              9.446e-02  4.884e-03   19.341  < 2e-16 ***
hour_cos              1.352e-01  4.510e-03   29.990  < 2e-16 ***
campus_distance_m     3.805e-04  2.625e-06  144.962  < 2e-16 ***
near_gsu1             7.788e-01  1.329e-02   58.606  < 2e-16 ***
near_ga_tech1         9.196e-01  1.679e-02   54.762  < 2e-16 ***
near_emory1           6.456e-01  6.723e-02    9.602  < 2e-16 ***
near_clark1           1.236e+00  2.152e-02   57.410  < 2e-16 ***
near_spelman1         1.064e+00  2.041e-02   52.125  < 2e-16 ***
near_morehouse1       6.077e-01  3.032e-02   20.044  < 2e-16 ***
near_morehouse_med1   1.247e+00  4.149e-02   30.057  < 2e-16 ***
near_atlanta_metro1   1.147e+00  2.342e-02   48.974  < 2e-16 ***
near_atlanta_tech1    1.217e+00  2.740e-02   44.395  < 2e-16 ***
near_scad1            9.107e-01  1.387e-02   65.648  < 2e-16 ***
near_john_marshall1   8.341e-01  1.566e-02   53.263  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 548366  on 1074499  degrees of freedom
Residual deviance:  60440  on 1074457  degrees of freedom
AIC: 268945

Number of Fisher Scoring iterations: 8
```

Figura 3: Summary del modello di Poisson

Il modello di Poisson riporta tutti i predittori inseriti come statisticamente significativi; tuttavia, riporta dei risultati che non ci convincono pienamente. Prendendo ad esempio i coefficienti legati alle npu con occorrenza maggiore (M, E, B), si nota un segno negativo che indica un impatto negativo sul numero medio di crimini commessi rispetto al livello di riferimento A, che però non compare tra i livelli più ricorrenti, quanto stimato è in contrasto con cosa ci aspetteremmo, mentre per altri distretti come F, N e V l'impatto è positivo e significativo. Il valore dell'intercetta è anch'esso negativo e indica che, fissati a zero tutti i predittori, il valore del numero medio di crimini commessi è praticamente pari a zero ($\exp(-5.298) = 0.005$).

Particolare attenzione può essere riposta al numero medio di crimini commessi negli ultimi 30 giorni, il quale produce, per ogni unità aggiuntiva, un aumento del 17% del valore medio del numero di crimini commessi in un'ora.

Tutte le variabili restanti, relative a fattori meteorologici e logistici, hanno un effetto positivo sul numero medio di crimini commessi in un'ora.

Passiamo ora in rassegna la stima del modello ZIP:

```
Call:
zeroinfl(formula = crime_count ~ npu + near_gsu + near_ga_tech + near_emory +
    near_clark + near_spelman + near_morehouse + near_atlanta_metro +
    near_scad + near_john_marshall | 1 + npu_crime_avg_30d, data = train_set)

Pearson residuals:
      Min        1Q    Median        3Q       Max
 -0.54174  -0.00593  -0.00586  -0.00570 216.56227

Count model coefficients (poisson with log link):
                    Estimate Std. Error z value Pr(>|z|)
(Intercept)          0.02037    0.03649   0.558  0.57672
npuB                 0.19921    0.03770   5.283 1.27e-07 ***
npuC                -0.12604    0.04402  -2.863  0.00420 **
npuD                -0.05827    0.04046  -1.440  0.14978
npuE                -0.22337    0.04128  -5.412 6.24e-08 ***
npuF                -0.01953    0.03982  -0.490  0.62384
npuG                 0.01104    0.04427   0.249  0.80312
npuH                 0.02754    0.04276   0.644  0.51945
npuI                 0.03210    0.04075   0.788  0.43081
npuJ                 0.01325    0.04336   0.306  0.75987
npuK                -0.23425    0.04932  -4.750 2.04e-06 ***
npuL                -0.35419    0.04692  -7.548 4.42e-14 ***
npuM                -0.25003    0.04080  -6.128 8.88e-10 ***
npuN                -0.02173    0.03981  -0.546  0.58520
npuO                 0.03094    0.04176   0.741  0.45878
npuP                 0.03460    0.04149   0.834  0.40428
npuQ                -0.01874    0.11560  -0.162  0.87120
npuR                 0.04153    0.04071   1.020  0.30767
npuS                -0.02092    0.04318  -0.484  0.62804
npuT                -0.18187    0.04408  -4.126 3.69e-05 ***
npuV                -0.21535    0.04301  -5.007 5.52e-07 ***
npuW                -0.06476    0.04020  -1.611  0.10719
npuX                 0.02144    0.04200   0.510  0.60974
npuY                -0.12104    0.04661  -2.597  0.00941 **
npuZ                 0.02991    0.04159   0.719  0.47193
near_gsu1            0.34517    0.01475  23.407  < 2e-16 ***
near_ga_tech1        0.42905    0.01935  22.179  < 2e-16 ***
near_emory1          0.09831    0.07784   1.263  0.20662
near_clark1          0.33377    0.02748  12.145  < 2e-16 ***
near_spelman1        0.25360    0.02344  10.818  < 2e-16 ***
near_morehouse1      0.40605    0.03367  12.058  < 2e-16 ***
near_atlanta_metro1  0.20520    0.02573   7.974 1.54e-15 ***
near_scad1           0.31575    0.01522  20.750  < 2e-16 ***
near_john_marshall1  0.45736    0.01837  24.895  < 2e-16 ***

Zero-inflation model coefficients (binomial with logit link):
                  Estimate Std. Error z value Pr(>|z|)
(Intercept)         9.5870     0.1741  55.051   <2e-16 ***
npu_crime_avg_30d -24.0138   273.4036  -0.088     0.93
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Number of iterations in BFGS optimization: 55
Log-likelihood: -8.969e+04 on 36 Df
```

Figura 4: Summary del modello ZIP

A differenza del modello di Poisson, il modello ZIP utilizza una parte dei predittori per modellare gli zeri strutturali; nel modello stimato, tale valore è costante perchè

dato dalla sola intercetta e pari a:

$$\hat{\pi} = \frac{\exp(\hat{\beta}_0)}{1+\exp(\hat{\beta}_0)} = \frac{\exp(9.587)}{1+\exp(9.587)} = \\ = 0.9999314 \tag{8}$$

mentre il coefficiente lambda è dato da:

$$\begin{aligned}\hat{\lambda} = \exp(&+0.199 * npuB+ \\ &-0.126 * npuC - 0.223 * npuE+ \\ &-0.234 * npuK - 0.354 * npuL+ \\ &-0.25 * npuM - 0.181 * npuT+ \\ &-0.215 * npuV - 0.121 * npuY+ \\ &+0.345 * near_gsu+ \\ &+0.429 * near_ga_tech+ \\ &+0.334 * near_clark+ \\ &+0.254 * near_spelman+ \\ &+0.406 * near_morehouse+ \\ &+0.205 * near_atlanta_metro+ \\ &+0.316 * near_scad+ \\ &+0.457 * near_john_marshall)\end{aligned} \tag{9}$$

dove i coefficienti inseriti sono solo quelli per i livelli e per le variabili statisticamente significative al 5%.

In questo modello, gli effetti significativi per l'appartenenza a una determinata npu sono tutti negativi, fatta eccezione del quartiere B, con una magnitudine piccola, la quale viene solitamente bilanciata dalla vicinanza a determinati punti di interesse, che hanno quasi nella loro totalità effetti positivi e significativi. Il numero medio di crimini nella npu di riferimento risulta essere non significativa, tuttavia per questioni di stabilità del modello si è deciso di stimarlo comunque includendo tale variabile nella parte dedicata alla modellazione della zero inflation.

Passiamo ora all'analisi del modello Hurdle stimato:

```
Call:
hurdle(formula = crime_count ~ npu + near_gsu + near_ga_tech + near_emory +
    near_clark + near_spelman + near_morehouse + near_atlanta_metro +
    near_scad + near_john_marshall | 1 + npu_crime_avg_30d, data = train_set,
    dist = "poisson", zero.dist = "binomial", link = "logit")

Pearson residuals:
      Min        1Q    Median        3Q       Max
 -3.937197 -0.006477 -0.006419 -0.006373 344.285862

Count model coefficients (truncated poisson with log link):
                  Estimate Std. Error z value Pr(>|z|)
(Intercept)        -3.14262    0.24911 -12.616  < 2e-16 ***
npuB                2.33052    0.24995   9.324  < 2e-16 ***
npuC               -0.20762    0.27481  -0.755 0.449950
npuD                0.55790    0.25648   2.175 0.029613 *
npuE                0.22935    0.25333   0.905 0.365291
npuF                0.72189    0.25593   2.821 0.004793 **
npuG                0.39695    0.28609   1.388 0.165281
npuH                0.81400    0.26910   3.025 0.002487 **
npuI                0.90215    0.26145   3.451 0.000559 ***
npuJ                0.50940    0.27794   1.833 0.066834 .
npuK               -0.99274    0.30858  -3.217 0.001295 **
npuL               -0.96367    0.27208  -3.542 0.000397 ***
npuM                0.26713    0.25255   1.058 0.290184
npuN                0.75744    0.25539   2.966 0.003018 **
npuO                0.88105    0.26479   3.327 0.000877 ***
npuP                0.94978    0.26300   3.611 0.000305 ***
npuQ               -0.58714    1.02867  -0.571 0.568151
npuR                1.06813    0.25952   4.116 3.86e-05 ***
npuS                0.24707    0.27128   0.911 0.362409
npuT               -0.27776    0.26357  -1.054 0.291951
npuV               -0.54546    0.26260  -2.077 0.037788 *
npuW                0.40599    0.25749   1.577 0.114850
npuX                0.72042    0.26496   2.719 0.006548 **
npuY               -0.94012    0.29430  -3.194 0.001401 **
npuZ                0.86058    0.26455   3.253 0.001142 **
near_gsu1           1.56744    0.03271  47.924  < 2e-16 ***
near_ga_tech1       1.90377    0.04161  45.755  < 2e-16 ***
near_emory1         0.80277    0.24156   3.323 0.000890 ***
near_clark1         1.37631    0.06650  20.697  < 2e-16 ***
near_spelman1       1.55814    0.06423  24.257  < 2e-16 ***
near_morehouse1     1.15417    0.05690  20.285  < 2e-16 ***
near_atlanta_metro1  1.67271    0.09073  18.436  < 2e-16 ***
near_scad1          1.46334    0.03098  47.240  < 2e-16 ***
near_john_marshall1  1.72250    0.03447  49.964  < 2e-16 ***
Zero hurdle model coefficients (binomial with logit link):
                Estimate Std. Error z value Pr(>|z|)
(Intercept)     -10.0668     0.1741 -57.828   <2e-16 ***
npu_crime_avg_30d  24.0134   215.0491   0.112    0.911
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Number of iterations in BFGS optimization: 46
Log-likelihood: -2.88e+04 on 36 Df
```

Figura 5: Summary del modello Hurdle

Il modello Hurdle stimato utilizza esattamente lo stesso set di predittori utilizzati per la stima del modello ZIP; la prima differenza che si può notare è nel modo in cui vengono modellati gli zeri, anche in questo caso è un valore costante, ma di magnitudine e segno diametralmente opposti:

$$\hat{\pi} = \frac{\exp(\hat{\beta}_0)}{1+\exp(\hat{\beta}_0)} = \frac{\exp(-10.067)}{1+\exp(-10.067)} = \\ = 0.0000425 \tag{10}$$

tale risultato è coerente alla definizione della funzione di densità di probabilità del modello. Il coefficiente lambda è stimato

come:

$$\begin{aligned}\hat{\lambda} = \exp(&-3.143 + 2.33 * npuB + \\ &+ 0.558 * npuD + 0.722 * npuF + \\ &+ 0.814 * npuH + 0.902 * npuI + \\ &- 0.993 * npuK - 0.964 * npuL + \\ &+ 0.757 * npuN + 0.881 * npuO + \\ &+ 0.95 * npuP + 1.07 * npuR + \\ &- 0.545 * npuV + 0.72 * npuX + \\ &- 0.94 * npuY + 0.861 * npuZ + \\ &+ 1.567 * near_gsu + \\ &+ 1.904 * near_ga_tech + \\ &+ 0.803 * near_emory \\ &+ 1.376 * near_clark + \\ &+ 1.558 * near_spelman + \\ &+ 1.154 * near_morehouse + \\ &+ 1.673 * near_atlanta_metro + \\ &+ 1.463 * near_scad + \\ &+ 1.723 * near_john_marshall)\end{aligned} \tag{11}$$

Rispetto al modello ZIP, si può notare una diversa distribuzione dei residui di Pearson, con un valore massimo molto maggiore di quello riscontrato per il secondo modello analizzato (344.26 vs 216.56).

3.1 Confronto previsivo

Passiamo ora in rassegna le performance previsive sul test set dei tre modelli stimati precedentemente; in particolare, faremo riferimento alle misure di accuratezza: RMSE (Root Mean Squared Error) e MAE (Mean Absolute Error), calcolate come segue:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{12}$$

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{13}$$

Tali metriche sono riportate nella figura seguente:

```
              RMSE        MAE
ZIP     0.09152944 0.01567072
Hurdle  0.09275843 0.01383038
Poisson 0.18606619 0.04839331
```

Dal punto di vista del RMSE, il modello ZIP e il modello Hurdle sono quasi equivalenti, con il primo leggermente migliore; considerando invece il MAE, il modello Hurdle risulta migliore. Consci che la magnitudine di tali risultati proviene dalla natura dei dati, approfondiamo in che modo i due modelli producono tali errori, visualizzando i barplot delle previsioni contro quello dei valori veri nel test set.

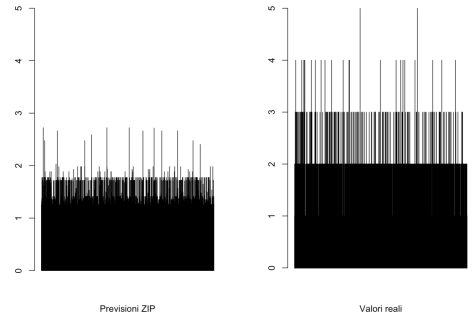


Figura 6: Confronto tra valori reali e stimati con il modello ZIP

Per il modello ZIP si può notare una forte tendenza alla sottostima delle previsioni rispetto ai valori reali, soprattutto per un numero di crimini commessi in un'ora superiore a tre.

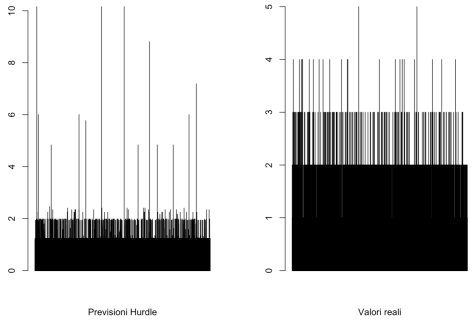


Figura 7: Confronto tra valori reali e stimati con il modello Hurdle

D'altro canto, per il modello Hurdle si può facilmente identificare una tendenza a

sovrastimare il numero di crimini commessi, pur notando come il modello sia in grado di intercettare quando il numero di crimini commessi è particolarmente elevato.

4 Conclusioni

In conclusione, tra i modelli proposti per la previsione del numero di crimini commessi in un'ora nella città di Atlanta, data la natura dei dati che presenta oltre il 90% delle osservazioni pari a zero nella variabile di risposta, e date le performance previsive ottenute sul test set è possibile scegliere tra un modello ZIP (Zero-Inflated Poisson) e un modello Hurdle Poisson. Il primo modello tende a sottostimare sistematicamente il numero di crimini commessi quando questi sono superiori a tre, il secondo, al contrario, tende a sovrastimarne il numero sebbene dimostri la capacità di intercettare le variabili che incidono su tale evenienza. La scelta di un modello rispetto all'altro dovrebbe essere sostenuta anche rispetto all'obiettivo del committente dell'analisi. Ipotizzando che le previsioni ottenute con il modello servano a determinare quante pattuglie della polizia debbano risultare attive sul territorio cittadino, nell'ambito delle loro attività, allora la scelta del primo modello ridurrebbe il rischio di investire più tempo e personale del dovuto, con il rischio di ritrovarsi con personale insufficiente in caso di necessità; un trade-off contrario si verificherebbe qualora si decidesse di scegliere il modello Hurdle, con un dispiego di personale talvolta maggiore del necessario che comporta anche maggiori costi di gestione.

I due modelli sono alternativi; tuttavia, tra i due, la capacità di intercettare valori alti per il numero di crimini dell'uno e la sistematicità delle sottostime dell'altro, fanno ricadere la scelta del modello ottimale sul modello Hurdle Poisson.